

ScenarioForge

소스코드 하나로 사용자 여정 시나리오를 만들고
실제 화면에서 실행한다

100%

골든 대비 재현

업무 분류 · 업무흐름 · 여정

97.4%

화면 요소 그라운드링

좌표계 계약 적용 후

2 개 앱

왕복 실행 통과

실제 앱에서 step 전부 통과

멘티

양권상 11769

멘토

강준형 · 이용택



01 프로젝트 개요

왜 했는가 · 무엇을 만들었는가 · 어떤 성과를 냈는가

🎯 문제 정의

대규모 SI 통합테스트 1 차수 (케이스 1,000 건) 를 사람이 쓰고 수행하고 캡처하면 **~115 MD** 가 든다 . 기존 자동 생성은 전이 coverage 100% 에도 완주 가능한 여정을 만들지 못했다 . 이 흐름을 자동화해 **차수당 공수를 ~74% 줄인다** .

Impact 증적에만 37.5 MD 가 들고 차수마다 다시 든다 . 시나리오 · 실행 · 증거가 하나로 이어지면 이 공수가 검토로 바뀐다 .

~115 MD

As-Is · 수작업 수행과 증적

케이스 1,000 건 · 1 차수 기준 추정

~30 MD

To-Be · 검토와 수동 스텝

As-Is 건당 55 분 (작성 25 + 수행 12 + 증적 18)

~74%

차수당 공수 단축

🔧 핵심 기능 · Agent 흐름

□ 모델 출력을 코드로 검증하는 게이트

🏆 핵심 성과 실측

생성

스캐너

소스 범위를 정한다

Pi author

의미 5 단계를 쓴다

리뷰어

검토하고 고친다

생성이 끝난 뒤

골든 평가자

생성 후 채점한다

수행

step 컴파일러

실행 계획을 만든다

operator

위치를 제안한다

제안 게이트

코드로 검증한다

observer

결과를 관측한다

판정 엔진

합격을 정한다

기술 스택 Electron · React · TypeScript · SQLite · Vitest · **Pi coding agent SDK** × **Azure OpenAI gpt-5.6-luna**

100%

정확도 골든 대비 recall

분류 6 개 · 흐름 10 개 · 여정 2 개 전부 재현

6 / 6

성공률 실제 앱 2 개 왕복 실행 step

그라운드링 20.5% → 97.4%

0 → 2

체감 완주 가능한 사용자 여정

증적에 좌표계 3 값 기록 · 판정 재현 가능


KEY MESSAGE

소스코드만으로 **끝까지 따라 할 수 있는 여정 시나리오**를 만들고 , 실제 화면에서 실행해 증거까지 남긴다 .

02 기술 아키텍처

어떻게 만들었는가 · 왜 이 기술을 선택했는가

시스템 아키텍처 사용자 액션 → 데이터 흐름



💡 핵심 기술 선택 이유

- 1 백엔드 소유 정보 + 모델 의미 patch 를 선택**
0 참조 오류 재발
기존 한계 모델이 JSON 전체를 쓰면 정보 ID 를 변형해 참조 오류가 반복됐다.
선택 ID · 근거 · hash 는 백엔드가 결정론적으로 만들고, 모델에는 **실행 한정 opaque 참조만** 노출한다.
ownership boundary · evidence grant · LLM-Wiki 식 누적 산출물 컨텍스트 관리
- 2 상한 있는 Self-Correction 루프를 선택**
4/5 단계 로컬 검증 통과
기존 한계 검증 실패를 모두 종료로 다루면 run 마다 다른 자리에서 실패해 수렴하지 않았다.
선택 리뷰어 issue 를 같은 작업 안에서 고치는 **bounded repair** 를 쓴다. 신뢰 경계 위반만 fail-closed 로 끊는다.
ref. Self-Refine · Reflexion (2023) · 독립 리뷰어 세션
- 3 bounded vision step + operator/observer 분리를 선택**
4/4 observer 음성 대조
18/18 앵커 신뢰도
기존 한계 순수 CUA 는 10 step 을 넘으면 35% 로 붕괴하고 회차마다 전량 VLM 을 호출한다.
선택 모델에는 **라벨 위치만 묻고** 계획과 판정은 코드가 한다. observer 세션을 분리해 자기 판정을 막는다.
ref. OSWorld · SeeAct (2024) · VLM grounding · long-horizon 계획

평가 분리
골든 데이터셋을 **생성에 노출하지 않았고**, 생성이 끝난 뒤 분리된 세션의 LLM-as-judge 가 항목당 유사도 0.7 이상만 일치로 인정한다.

03 핵심 기술 과제

어떤 장벽이었나 · 어떻게 돌파했나 · 수치로 얼마인가

⚠ 그냥 구현으로는 풀리지 않았던 세 가지 왜 기존 방법이 안 되는가, 어떻게 풀었는가, 결과는 얼마인가

1 좌표계 불일치로 그라운드링 20.5%

왜 기존 방법으로 안 되는가

VLM 이 짧은 변을 768 로 리사이즈하는 전처리 탓에 모델 좌표계와 캡처 좌표계가 어긋났다. 39 개 대상의 오차가 전부 선형이고 세로 배율이 0.853, 즉 768/900 이었다. **계통 오차**라 모델이나 프롬프트를 바꿔도 풀리지 않는다.

엔지니어링 접근 · 설계 결정

좌표계 계약을 고정했다. 리사이즈 전송과 캡처 좌표 환산을 필수 계약으로 두고, 환산은 모델이 아니라 제안 게이트 (코드) 가 맡는다. 증적에는 좌표계 3 값을 남긴다.

AGENT LOG

GATE replay 64 → 옳은 제안 53 통과 · 틀린 1 통과 · 과차단 5→0
VERDICT 도착 하면 불일치 → 조작 · 게이트 성공이어도 FAILED

결과

20.5% → 97.4%

AXSE 39 개 중 38 개 · RA-DAR 71.4% · 환산 좌표 1px 이내

2 환각을 스키마로 막을 수 없었다

왜 기존 방법으로 안 되는가

JSON Schema 와 structured output 은 **형식만 보장한다**. ID 변형과 guard 누락이 run 마다 다른 자리에서 재발해, 규칙을 더해도 수렴하지 않는다.

엔지니어링 접근 · 설계 결정

소유권 경계와 repair loop 로 나눴다. 정보 구조인 ID 와 hash, 근거는 백엔드가 소유하고 모델은 의미만 patch 한다. 누락은 허용 범위 안에서 다시 읽어 메운다.

AGENT LOG

HANDOFF gap 3 건 → 허용 소스 6 개 재읽기 → 의미 gap 전부 해소
VERIFY evidence 22 건 정합 · hash 일치

결과

재발 0 · recall 100%

참조 오류 재발 0 건 · 골든 대비 recall 100%

3 429 재시도 증폭과 payload 팽창

왜 기존 방법으로 안 되는가

재시도 계층이 겹쳐 에이전트 SDK 4 회와 실행기 3 회가 곱해지면 최대 12 회를 호출한다. **retry storm** 이 rate limit 을 다시 악화시키고, 누적 컨텍스트 탓에 요청당 약 104K 토큰까지 부른다.

엔지니어링 접근 · 설계 결정

재시도를 한 곳이 소유하게 바꿨다. 중복 요청을 제거하고, 단계 사이에는 전문 대신 소형 영수증 (receipt) 만 넘긴다.

AGENT LOG

RETRY Pi 4 회 × 실행기 3 회 = 12 회 → 소유자 단일화
PAYLOAD ~104K tok/req → 중복 제거 + receipt

결과

rate limit 0 건

동일 입력이 rate limit 없이 완주

배운 것 · 다음 단계

미달 2 개의 원인은 모델 성능이 아니라 AI 에게 **어디까지 시킬 것인가**였다.

시나리오 성공 recall 37.5% → 80%

전이 원장과 경로 컴파일러를 연결한다

RA-DAR 그라운드링 71.4% → 90%

라벨 가시성 필드를 추가한다